Armadilhas comuns e perguntas para explorar

Leia junto com o dicionário de dados. Os erros abaixo não são de código: são de **interpretação**, e é neles que análises tecnicamente corretas chegam a conclusões erradas.

Armadilhas

1. Tirar a média das taxas

A média simples de `taxa_desvinculo` dá o mesmo peso a um curso com 10 alunos e a um com 10.000. Para a taxa de um grupo, some numeradores e denominadores:

```
# errado
cursos.groupby("rede").taxa_desvinculo.mean()
# certo
g = cursos.groupby("rede")[["desvinculados", "vinculos"]].sum()
g.desvinculados / g.vinculos
```

Na trajetória, pondere pelos ingressantes: `(tda_% × ingressantes).sum() / ingressantes.sum()`. Cursos com poucos alunos (`poucos_alunos = 1`) têm taxas muito instáveis. Considere filtrá-los.

2. Atribuir ao curso o que é da instituição

Duas características de curso podem parecer ligadas à evasão só porque aparecem em **tipos diferentes de instituição**: rede, porte, região, quem preenche bem o Censo. Antes de concluir que "cursos com X perdem menos alunos", compare cursos **dentro da mesma instituição e do mesmo ano**:

```
cursos.groupby(["ano", "co_ies", "tem_x"])[["desvinculados", "vinculos"]].sum()
```

Se a diferença sumir dentro das instituições, o efeito era da instituição, não do curso.

3. Comparar turmas com tempos de acompanhamento diferentes

Em `trajetoria_cursos`, a turma de 2020 foi acompanhada por 4 anos e a de 2015 por 9. A turma de 2020 ainda tem muita gente cursando e, por isso, menos gente que "já desistiu". Para comparar turmas, use `trajetoria_cursos_anual` com o **mesmo** `anos_desde_ingresso`.

4. Misturar as três medidas de evasão

Medida	Onde	Ordem de grandeza	Pergunta que responde
`taxa_desvinculo`	`cursos_ano`	17–23% ao ano	Que fração dos alunos do curso se desvinculou **neste ano**?
`tda_%`	`trajetoria_cursos`	~60% em 2024	De cada 100 que **entraram** no curso, quantos desistiram até 2024?
`evasao`	`fluxo_inep_contexto`	13–18% ao ano	Que fração saiu do **ensino superior** de um ano para o outro?

Os três números estão certos e medem coisas diferentes. Sair de um curso não é sair do ensino superior: o aluno pode ter trocado de curso ou de instituição. Diga sempre qual medida está usando.

5. Quebras de série

- `mat_apoio_social` **na rede privada** cai bruscamente entre 2022 e 2023, provavelmente por mudança na forma de coleta. Não compare antes e depois de 2023 nessa rede.
- **Classificação Cine:** em 2024 o INEP reclassificou os cursos de Computação/TIC. As colunas `cine_*` já usam uma classificação única por curso, mas `cine_rotulo_original` não.
- **Cursos que abrem e fecham:** uma série temporal com todos os cursos mistura mudança real com mudança na composição. Para evolução no tempo, filtre `presente_5_anos == 1`.
- **Pandemia:** 2020 e 2021 podem refletir efeitos atípicos.
- **Desemprego de 18 a 24 anos por UF** só existe para 2023 e 2024.

6. Zero que quer dizer "não informado"

Várias instituições não registram nenhum aluno com apoio social no Censo. Nelas, `mat_apoio_social = 0` não quer dizer "ninguém recebe apoio". Antes de tirar conclusões sobre um curso, confira o total da instituição em `ies_ano`.

7. Viés de sobrevivência

`qualidade_cursos` (CPC, Enade, IDD e as notas dadas pelos alunos) descreve **quem chegou ao fim do curso**. Quem desistiu não fez o Enade nem respondeu o questionário. Use com cuidado para explicar a evasão.

8. Onde fica um curso EAD

- A UF de um curso EAD é a do **polo** onde estão os alunos, não a da sede da instituição (`uf_sede_ies`).
- Em `cursos_ano`, `uf_principal` de um curso EAD é só a UF com mais alunos. Para análise por estado, use `cursos_uf_ano`.
- Em `trajetoria_cursos`, cursos EAD não têm UF.
- `matriculas_por_docente` fica enorme em instituições EAD, porque tutores não contam como docentes.

9. Poucas observações parecem padrões

Com 27 UFs ou 69 universidades federais, qualquer correlação é frágil e sensível a um ou dois casos extremos. Verifique se a relação se mantém ao controlar por rede e modalidade, e trate-a como hipótese, não como prova.

10. O que os dados não permitem dizer

- **Não há dados por aluno.** Não dá para afirmar que "alunos com perfil X evadem mais", só que "cursos com mais alunos X têm taxas maiores", que é uma afirmação diferente e mais fraca.
- **Recortes por sexo, cor-raça, idade e deficiência** existem só em `fluxo_inep_contexto`, no nível Brasil/região/UF.
- **Associação não é causa.** Para dizer que uma política *reduz* a evasão, é preciso um desenho que compare casos parecidos (antes e depois, dentro da mesma instituição etc.).

Perguntas para explorar

Pontos de partida, não gabarito. Cada um cabe no prazo do evento e pode levar a propostas diferentes.

- **Modalidade:** a expansão do EAD muda o retrato da evasão no Brasil? Como o EAD público e o privado se comparam?
- **Tempo:** houve mudança de patamar em algum ano do período? Ela aparece em todas as redes e modalidades?
- **Turmas:** as turmas mais recentes desistem mais, ou mais cedo, que as anteriores?
- **Quando se desiste:** em que ano do curso a desistência se concentra? Isso varia por área ou modalidade?
- **Qualidade:** cursos com melhor avaliação (CPC, notas dos alunos) retêm mais?
- **Política pública:** o investimento em assistência estudantil (PNAES) acompanha a vulnerabilidade dos alunos de cada universidade federal? Há relação com a permanência?
- **Território:** o contexto da UF (renda, desigualdade, desemprego) ajuda a entender a evasão ao considerar rede e modalidade?
- **Perfil do curso:** cursos noturnos, com mais alunos de escola pública, com FIES ou ProUni têm trajetórias diferentes?
- **Na nossa casa:** como está a USP (`co_ies = 55`) em relação a outras universidades públicas? Quais cursos merecem atenção?