Nível 1 — Dado observado

Verossimilhança

$$Y_{it} \mid p_{it} \sim \text{Binomial}(N_{it},\, p_{it}), \qquad Y_{it} < N_{it}$$

- Y_{it}: número de sucessos observados no curso i, IES j, ano t.
- N_{it}: número de tentativas (conhecido).
- p_{it}: probabilidade de sucesso, **latente** (não observada).
- A condição $Y_{it} < N_{it}$ trunca o suporte: para $y < N$,

$$P(Y = y \mid Y < N) = \frac{\binom{N}{y} p^y (1-p)^{N-y}}{1 - p^N}.$$

Nível 2 — Probabilidade latente

Distribuição Beta (média e precisão)

$$p_{it} \sim \mathrm{Beta}(\mu_{it}, \phi_{it}), \qquad \mathbb{E}[p_{it}] = \mu_{it}, \quad \mathrm{Var}(p_{it}) = \frac{\mu_{it}(1-\mu_{it})}{1+\phi_{it}}$$

- $\mu_{it} \in (0,1)$: média; $\phi_{it} > 0$: precisão.
- Equivale a $\mathrm{Beta}(a,b)$ com $a = \mu\phi$ e $b = (1-\mu)\phi$.
- Cada unidade tem sua própria probabilidade $\Rightarrow$ **superdispersão** em relação à binomial.
- Quanto maior ϕ, menor a dispersão de p em torno de μ.

Nível 3 — Preditores para média e precisão

Funções de ligação

$$\operatorname{logit} \mu_{it} = \mathsf{x}_{it}^{\top}\boldsymbol{\beta} + u_j + u_i, \qquad \log \phi_{it} = \mathsf{z}_{it}^{\top}\boldsymbol{\gamma} + v_j + v_i$$

- logit garante $\mu \in (0,1)$; log garante $\phi > 0$.
- $\mathsf{x}_{it}, \mathsf{z}_{it}$: covariáveis conhecidas; $\boldsymbol{\beta}, \boldsymbol{\gamma}$: efeitos fixos.
- u_j, v_j: efeitos aleatórios de IES; u_i, v_i: efeitos aleatórios de curso.
- μ_{it} e ϕ_{it} são **determinísticos** dados seus pais no grafo.

Nível 4 — Efeitos aleatórios

Distribuições

$$u_j \sim N(0, \sigma^2_{\text{IES}}), \quad u_i \sim N(0, \sigma^2_{\text{curso}}),$$
$$v_j \sim N(0, \tau^2_{\text{IES}}), \quad v_i \sim N(0, \tau^2_{\text{curso}}).$$

- Desvios latentes, independentes e de média zero: capturam a heterogeneidade não explicada pelas covariáveis.
- u atua sobre a média (μ); v atua sobre a precisão (ϕ).
- Mecanismo de *partial pooling*: unidades do mesmo grupo compartilham informação.

O que precisa ser estimado

Vetor de parâmetros

$$\boldsymbol{\theta} = \left(\boldsymbol{\beta},\ \boldsymbol{\gamma},\ \sigma^2_{\text{IES}},\ \sigma^2_{\text{curso}},\ \tau^2_{\text{IES}},\ \tau^2_{\text{curso}}\right)$$

- $\boldsymbol{\beta}, \boldsymbol{\gamma}$: efeitos fixos das covariáveis sobre a média e a precisão.
- σ^2, τ^2: variabilidade entre IES e entre cursos (média e precisão).
- Latentes $(u_j, u_i, v_j, v_i, p_{it})$: **não** entram em $\boldsymbol{\theta}$; são integrados na verossimilhança ou amostrados (abordagem bayesiana).
- Na abordagem bayesiana, $\boldsymbol{\theta}$ requer distribuições *a priori*.

Consequência marginal: Beta-Binomial

Variância marginal (sem truncagem)

$$\mathrm{Var}(Y_{it}) = N_{it}\mu_{it}(1-\mu_{it})\left[1 + \frac{N_{it}-1}{1+\phi_{it}}\right]$$

- Integrando p_{it} obtém-se a distribuição Beta-Binomial.
- O termo entre colchetes é o **fator de superdispersão**.
- Quando $\phi_{it} \to \infty$, o fator tende a 1 e recuperamos a Binomial.